

使用遗传算法优化的神经网络预测每日汇率

概要

预测汇率是一个重要的金融问题，由于其固有的难度和实际应用而受到了广泛关注。外汇汇率的统计分布及其线性不可预测性是国际金融文献中经常出现的主题。各种结构计量经济模型和基于线性时间序列技术的模型无法为所有模型中最简单的模型即简单随机游走模型提供出色的预测，促使研究人员使用了各种非线性技术。为了改善简单随机游走模型的性能，最近已经提出了许多非线性时间序列模型来获得准确的预测结果。在本文中，我们使用基于神经网络和遗传算法的混合人工智能方法对每日汇率进行建模。还对提出的方法与非线性统计模型进行了详细的比较。结果表明，与传统的非线性时间序列技术和固定几何神经网络模型相比，该方法具有更好的性能。

关键词：人工智能 自回归条件；异方差；反向传播 外汇牌价；
前馈网络；遗传算法 神经网络；随机行走 循环网络

介绍

对于应用计量经济学家和统计学家来说，建立汇率预测模型一直是充满挑战的研究领域。Meese和Rogoff (1983) 指出了所涉及的困难，发现基于汇率确定的货币和资产理论的几种重要结构模型所产生的预测的效果不及（就样本外预测能力而言）所有模型中最简单的模型，即简单的随机游走模型。

布特和格拉斯曼 (Booth and Glassman, 1987) 也证实了这些发现，反映了1976-1984年（即布雷顿森林时代）的许多关键汇率。亚历山大和托马斯 (1987) 和沃尔夫 (1987) 进一步证明，即使将时变参数合并到模型中，随机游走模型也要优于这些计量模型。Wolff (1988) 使用时变自回归模型得出了类似的结论。尽管这些结果支持有效市场假说，但研究人员仍在继续探索各种替代技术来进行汇率建模。

由于这些经验研究主要依赖于线性时间序列技术，因此可以推测汇率的线性不可预测性可能是由于线性模型的局限性，这并非没有道理。虽然汇率的变化是线性不相关的，但是一些研究（例如见Hsieh, 1989; Papell和Sayers, 1990; Diebold和Pauly, 1988）能发现非线性行为的证据也很好了。Meese和Rose (1991) 也表明汇率表现出明显的非线性。但是，经过相当广泛的经验搜索后，他们仍然无法找到一个控制随机游走样本外性能的非线性模型。Chinn (1991) 还通过使用交替条件期望模型为非线性汇率模型提供了一些支持。

最近的许多文章提出了在汇率序列中存在自回归条件异方差 (ARCH) 效应的证据。参见例如Bollerslev等人 (1992) 的评论。ARCH模型及其后来的变体（例如ARCH-M和GARCH-M）解释了金融市场价格中最明显的非线性结构类型，即价格的小（大）幅变化紧接着是两个符号的小（大）幅变化。ARCH模型由Engel (1982) 引入计量经济学文献，随后由Bollerslev (1986) 等人通过广义ARCH (GARCH) 模型进行了概括。最近也有证据表明，汇率变化的条件均值中存在非线性依赖性。误差项的条件方差被用作解释这些模型中条件均值的回归指标之一。有结果表明，与随机游走和其他非线性模型（如双线性模型）相比，考虑条件异方差性可以更好地预测月汇率（参见Nachne和Ray, 1993）。

基于神经网络的模型的使用是研究人员可以用来捕获汇率序列中潜在的非线性的另一种选择。基于人工神经网络 (ANN) 的模型具有多个功能，使其成为一种有吸引力的预测工具。首先，与传统的基于模型的方法相反，基于ANN的模型是数据驱动的和自适应的。其次，人工神经网络是通用函数逼近器。已经表明，网络可以将任何连续函数近似到任何期望的精度 (Hornik, 1991)。最后，人工神经网络是非线性模型。现实世界中的系统通常是非线性的，这导致了过去十年来一些非线性时间序列模型的发展。它们包括双线性模型

(Granger和Anderson, 1978)，阈值自回归模型 (Tong和Lim, 1980) 和自回归条件异方差 (ARCH) 模型 (Engel, 1982) 等模型。ANN的非线性建模能力相对于这些模型具有明显的优势，因为在ANN下，无需指定输入和输出变量之间的函数关系。近年来，人工神经网络已被用作成功的预测工具。Zhang等人 (1998) 对该领域的研究现状进行了全面回顾。

使用人工神经网络（ANN）进行的汇率预测提供了证据，即就样本外预测能力而言，它们明显优于现有的统计方法。Refenes（1996）用每小时汇率数据观察到，ANN模型的性能远胜于指数平滑和自回归综合移动平均（ARIMA）模型。对于日汇率数据，Weigend等人（1992年）证明了人工神经网络要比随机游走模型好得多。利用每周的汇率数据，Hann和Steurer（1996）表明ANN优于线性模型。最近，Lisi和Schiavo（1999）对神经网络模型和混沌模型进行了详细的比较，以预测月汇率。他们发现，神经网络与混沌模型相比具有优势，并且两者的性能都明显优于随机游走模型。

因此，基于ANN的各种频率汇率预测方法的成功是一个公认的事实。但是，众所周知（Refenes，1996），通过标准神经网络训练算法（例如反向传播）获得的解决方案存在严重缺陷。这些包括收敛到局部极小值的可能性，以及通过实验寻找最佳网络架构的可能性。由于没有关于网络体系结构参数的先验现实估计，因此网络设计在很大程度上取决于人工实验和学习参数的微调。因此，尽管汇率的人工神经网络模型报告了优越的性能，但仍有进一步改进的空间。

本文的目的是建立不遭受传统固定几何ANN模型缺点的ANN汇率模型，并且其性能要好得多。所提出的人工神经网络模型使用遗传算法搜索程序来优化人工神经网络架构参数。此外，使用此过程有助于避免解决方案陷入局部最小值。使用提议的程序，我们为主要的国际交易每日汇率，即德国马克/美元，日元/美元和美元/英镑汇率，构建了人工智能模型。还对这些模型与条件异方差模型（ARCH，GARCH，AGARCH，EGARCH和GARCH-M）进行了详细比较。

本文的其余部分安排如下。下一节介绍了用于预测每日汇率的遗传神经网络算法。第三部分报告了构建模型和实验发现的详细信息。最后一部分将讨论从实验过程得出的结论。

遗传工程人工神经网络模型

人工神经网络是一个研究领域，旨在建立一个计算上可行的基于机器的认知系统，该系统试图捕捉人类认知过程的关键方面。尽管就处理速度而言，人脑不如现代微处理器，但其优势在于可以组织输入变量的高维数组。并行或连接主义，适应性和自组织性是大脑信号处理机制的主要属性。从技术上讲，人工神经网络是一种信息处理技术，试图融合大脑和神经系统的这三个特征，并在某种程度上试图模仿人脑的功能。从统计学家的角度来看，人工神经网络可以描述为非线性，非参数，多元和完全由数据驱动的推理过程。

称为网络训练的迭代过程用于获得网络权重的最佳集合。像反向传播一样的训练算法通常用于前馈网络的训练。使用称为递归反向传播的算法训练非对称递归网络。除了网络的权重之外，ANN体系结构还有其他一些未知参数。其中包括输入单位的数量，输入单位的最佳组合，隐藏层的数量，每层隐藏神经元的数量，传递函数的类型（对于隐藏单位和输出单位），学习率的值和动量速率参数（后两个参数通常用于反向传播训练算法）。在没有关于这些参数的任何先验信息的情况下，对此的选择相当主观，并取决于实验者的经验。由于主观选择了人工神经网络的结构参数，因此始终存在解决方案陷入局部最小值的风险。理想地，必须在此类参数的整个参数空间上优化针对特定问题的网络体系结构。我们使用遗传算法搜索程序的 the survival of the fit test 来得出这些ANN体系结构参数的最佳值。

本节介绍了使用遗传算法提高常规固定几何神经网络性能的方法。遗传算法（GA）是基于自然选择和遗传机制的全局优化算法。标准GA优化问题的公式为

$$\left. \begin{array}{l} \text{Optimize } F(x) \\ \text{Subject to } x \in \Theta = \{0, 1\}^n \end{array} \right\} \quad (1)$$

要优化的函数 $F: \Theta \rightarrow \mathbb{R}$ 被称为拟合函数。为了开始遗传搜索，从 Θ 中选择有 N 个成员的初始种群 P_0 ，每个成员有 n 位（每位为0或1）。对初始人群的成员进行适合性评估。通过设计概率实验，为当前一代的成员选择能够在下一代中存活的方法，在该概率实验中，为每个成员分配与其适应度值成正比的生存概率。接下来找到存活的成员进行交叉（交配）以填补下一代。为了充分探索搜索空间，对这些字符串（染色体）进行了突变操作。变异算子是随

机先验补码，具有先验概率。变异有助于使搜索程序多样化，并向种群中引入新的字符串，并迫使种群中的多样性允许对更多的搜索空间进行采样，从而使搜索克服局部极小值，还有助于消除破坏性交叉效应。选择，交叉和变异的整个过程重复进行，直到达到收敛标准为止。

将标准遗传算法应用于给出的任意优化问题

$$\left. \begin{array}{l} \text{Optimize } G(y) \\ \text{Subject to } y \in \Omega \subset \mathbb{R}^n \end{array} \right\} \quad (2)$$

我们进行如下。

首先，通过可逆映射 $M: \Omega \rightarrow \Theta$ 来确定搜索空间 Ω 与二进制字符串 Θ 的空间之间的对应关系。最后，适当的适应度函数 $F(X)$ ，使 F 的优化器与 G 的优化器相对应。

当前问题中的参数空间包括输入单元的数量，输入单元的可能组合，隐藏层的数量，每一层的隐藏神经元的数量，传递函数的类型（对于隐藏单元和输出单元），学习率，动量率参数和权重向量的值。提出的遗传神经网络模型构建过程通过以下迭代步骤进行。

迭代算法

(1)在可能的输入变量和随机选择的网络体系结构内创建初始种群。最初的种群成员被转化为二进制编码的染色体($\Omega \rightarrow \Theta$)

(2)训练和测试这些网络，以确定它们对解决问题的适应程度。计算当前人口中每个受训网络的适合度。

(3)根据网络的适合度对网络进行排名，并通过设计概率实验来选择最佳网络。

(4)通过配对代表这些网络的权重，输入和神经结构的遗传材料来创造下一代。通过交换染色体的基因使选定的成员交配来完成。

(5)根据预先指定的突变概率以随机方式应用突变。

(6)重复训练/测试周期的阶段(2)，直到达到最佳人口。

该过程在一代又一代地继续进行，直到达到最佳的（根据一些预定标准）网络架构。

通过这个过程，更好的网络得以生存，它们的功能被延续到子孙后代，并与其他网络相结合，从而为特定应用找到更好的网络。这种遗传搜索方法比随机搜索更有效，因为重组特征的遗传过程极大地提高了识别高度匹配网络的速度。与仅使用个人经验来构建神经网络相比，它还具有潜在的优势，因为通过此过程可能会发现新的且可能更好的解决方案，否则，由于用户几乎不可避免的假设，这些解决方案可能会被忽略。

实证研究

在本节中，我们介绍针对三种主要国际交易汇率（即德国马克/美元，日元/美元和美元/英镑汇率）提出的基因工程神经网络模型的性能。在所有这些案例研究中，目标变量都是“第二天结束时关闭汇率”。还对所提出的方法与通常的固定几何神经网络和各种类型的条件异方差模型进行了比较。这三个系列从1992年1月至1998年5月的每日“现货市场”汇率数据取自路透社的数据处理。

为本研究构建的不同类型的神经网络：

(1) 遗传算法神经网络 (GANN)：使用该方法构造GANN

在上一节中进行了介绍。已经考虑了遗传前馈 (GFF) 和遗传反馈 (GFB) 网络。报告了常规平方误差损失 (SEL) 和绝对误差损失 (AEL) 函数的结果。GA应用于优化的初始参数空间如下所述：

输入层神经元：滞后因变量和技术指标。

隐藏层：最多两个。

隐藏层神经元：最多16个。

激活功能：S型，正切和线性。

初始人口数量：100。

学习率参数范围：0.1至0.85

动量速率参数范围：0.1至0.70

网络体系结构：前馈和反馈。

我们已经报告了以下四种GANN的性能：

- (a)使用绝对误差损失函数的遗传前馈网络 (GFF, AEL)
- (b)利用绝对误差损失函数的遗传反馈网络 (GFB, AEL)
- (c)使用平方误差损失函数的遗传前馈网络 (GFF, SEL)
- (d)使用平方误差损失函数的遗传反馈网络 (GFB, SEL)

(2) 固定几何神经网络 (FGNN)：用于与提出的作比较

具有固定几何网络的GANN网络我们报告了八种不同类型网络的性能。这些网络在隐藏神经元的数量 (8或16)，损失函数的类型 (AEL或SEL) 和激活函数的类型 (S型或双曲正切型) 方面有所不同。我们考虑具有这些参数的所有可能组合的网络。

条件异方差模型

还建立了各种条件异方差模型以与ANN模型进行比较。在本文中，我们构建了以下ARCH类型模型以与ANN模型进行比较：ARCH (1)，GARCH (1,1)，绝对GARCH (1,1)，指数GARCH (1,1) 和GARCH-in均值 (1,1) 或GARCH-M (1,1)。使用这些模型的原理与Nachne和Ray (1993) 中讨论的原理相同。

GARCH和GARCH-M类模型的成员可以写成

$$y_t = \beta' x_t + \delta h_t^2 + \varepsilon_t \quad (3)$$

where h_t^2 is the conditional variance of ε_t with respect to the information set Θ_{t-1} at time $(t-1)$ and is given by

$$h_t^2 = \text{Var}(\varepsilon_t | \Theta_{t-1}) = E(\varepsilon_t^2 | \Theta_{t-1}) = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \phi_i h_{t-i}^2 \quad (4)$$

xt向量包含自变量的值，也可能包含滞后的yt值。

For $\delta = 0$ in (3) and $p = 0$ and $q = 1$ in (4), we obtain the GARCH(0,1) or ARCH (1) model. For GARCH(p, q) models, $\delta = 0$ and $p \geq 0$ and $q \geq 0$ in (3) and there is no effect of conditional variance in the conditional expectation equation (3). For general GARCH-M models, $\delta \neq 0$, $p \geq 0$ and $q \geq 0$

考虑比较的两种其他类型的GARCH模型是绝对值GARCH (AGARCH) 和指数GARCH (EGARCH)。Heutschel (1991) 在文献中引入了AGARCH模型。对于AGARCH模型， ε_t 的条件标准误差为

$$h_t = \sqrt{\text{Var}(\varepsilon_t | \Theta_{t-1})} = \alpha_0 + \sum_{i=1}^q \alpha_i |\varepsilon_{t-i}| + \sum_{i=1}^p \phi_i h_{t-i} \quad (5)$$

EGARCH模型应归功于Nelson (1991)。对于这些模型，误差条件方差的对数有以下规定：

$$\log h_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \left(\frac{\varepsilon_{t-i}}{h_{t-i}} \right) + \sum_{i=1}^q \alpha_i^* \left(\left| \frac{\varepsilon_{t-i}}{h_{t-i}} \right| - \mu \right) + \sum_{i=1}^p \phi_i \log h_{t-i}^2 \quad (6)$$

为了评估不同模型的预测效果，我们保留了最后150个观测值作为“样本外”测试样本点。根据以下标准评估了人工智能和条件异方差模型的样本外预测性能：平均绝对误差 (AAE)，平均绝对百分比误差 (MAPE)，均方误差 (MSE)，最大绝对误差 (MaxAE) 和R平方 (RSQ)。ANN模型的结果列于表I - III。表I给出了德国马克/美元汇率的结果。表II给出了美元/英镑汇率的结果。日元/美元汇率的结果记录在表III中，条件异方差模型的结果显示在表I (a)，II (a) 和III (a) 中。

表I. 德国马克/美元ANN模型的样本外结果

Network type	Network structure	AAE	MAPE	MSE	Max AE	R-SQ
GANN	GAFB,AEL	6.066E-3	0.33635	7.494E-5	0.02781	0.86485
	GAFF,AEL	6.082E-3	0.33725	7.592E-5	0.26845	0.86209
	GAFB,SEL	6.186E-3	0.34273	7.433E-5	0.02532	0.86536
	GAFF,SEL	6.226E-3	0.34500	7.549E-5	0.02629	0.86275
FGNN	8H,AEL,SIG	7.033E-3	0.38981	8.925E-5	0.03295	0.83654
	8H,AEL,TANH	6.937E-3	0.38464	8.633E-5	0.03204	0.84320
	8H,SEL,SIG	7.184E-3	0.39834	9.216E-5	0.03481	0.83343
	8H,SEL,TANH	7.405E-3	0.40986	8.971E-5	0.03021	0.83938
	16H,AEL,SIG	7.258E-3	0.40265	9.585E-5	0.03471	0.83236
	16H,AEL,TANH	6.594E-3	0.36568	8.809E-5	0.03204	0.85348
	16H,SEL,SIG	7.677E-3	0.42503	9.979E-5	0.03499	0.81743
	16H,SEL,TANH	7.064E-3	0.39119	8.517E-5	0.02892	0.84721

Table I(a). Out-of-sample results for German deutsche mark/US dollar conditional heteroscedastic models

Model	AAE	MAPE	MSE	Max AE	R-SQ
ARCH(1)	6.204E-3	0.34353	7.967E-5	0.02606	0.85948
GARCH(1,1)	6.213E-3	0.34435	7.960E-5	0.02573	0.85987
AGARCH(1,1)	6.203E-3	0.34348	7.970E-5	0.02604	0.85958
EGARCH(1,1)	6.211E-3	0.34417	7.959E-5	0.02569	0.85983
GARCH(1,1)-M	6.203E-3	0.34430	7.953E-5	0.02568	0.85995

Table II. Out-of-sample results for US dollar/British pound ANN models

Network type	Network structure	AAE	MAPE	MSE	Max AE	R-SQ
GANN	GAFB,AEL	5.113E-3	0.30965	5.312E-5	0.02818	0.86033
	GAFF,AEL	5.162E-3	0.31259	4.963E-5	0.02681	0.86593
	GAFB,SEL	5.173E-3	0.31667	4.803E-5	0.02416	0.87057
	GAFF,SEL	5.116E-3	0.30980	4.799E-5	0.02451	0.87003
FGNN	8H,AEL,SIG	5.767E-3	0.34902	5.841E-5	0.02575	0.84755
	8H,AEL,TANH	5.636E-3	0.34119	5.577E-5	0.02549	0.85861
	8H,SEL,SIG	5.701E-3	0.34523	5.718E-5	0.02598	0.85666
	8H,SEL,TANH	5.657E-3	0.34261	5.598E-5	0.02391	0.86008
	16H,AEL,SIG	5.535E-3	0.33500	5.818E-5	0.02797	0.85344
	16H,AEL,TANH	5.523E-3	0.33431	5.516E-5	0.02536	0.86186
	16H,SEL,SIG	5.675E-3	0.34355	5.624E-5	0.02443	0.85707
	16H,SEL,TANH	5.747E-3	0.34794	5.764E-5	0.02488	0.85843

Table II(a). Out-of-sample results for US dollar/British pound conditional heteroscedastic models

Model	AAE	MAPE	MSE	Max AE	R-SQ
ARCH(1)	5.235E-3	0.31710	4.892E-5	0.02280	0.87020
GARCH(1,1)	5.294E-3	0.32065	5.022E-5	0.02354	0.86731
AGARCH(1,1)	5.327E-3	0.32267	5.080E-5	0.02385	0.86598
EGARCH(1,1)	5.254E-3	0.31821	4.968E-5	0.02349	0.86809
GARCH(1,1)-M	5.340E-3	0.32348	5.058E-5	0.02384	0.86732

从三种汇率的案例研究中可以看出，所有经过遗传优化的神经网络通常都比固定几何网络的性能好得多。不同固定几何网络的性能清楚地表明了为特定问题确定最佳拓扑和网络体系结构的难度。遗传神经网络的结果与固定几何网络的比较表明，在大多数情况下，固定几何网络被困在局部最小值附近。另一方面，使用遗传算法获得最佳拓扑可以定位误差表面的全局最小值，这是任何模型构建应用程序的最终目标。

Network type	Network structure	AAE	MAPE	MSE	Max AE	R-SQ
GANN	GAFB,AEL	0.63067	0.49687	0.73081	3.99584	0.94422
	GAFF,AEL	0.63261	0.49781	0.72854	4.04459	0.94445
	GAFB,SEL	0.64438	0.50758	0.72852	3.75515	0.94435
	GAFF,SEL	0.63857	0.50205	0.72196	3.90782	0.94476
FGNN	8H,AEL,SIG	0.69294	0.54423	0.83299	4.10183	0.93757
	8H,AEL,TANH	0.69166	0.54440	0.85113	3.74998	0.94058
	8H,SEL,SIG	0.68275	0.53619	0.78697	3.88950	0.93993
	8H,SEL,TANH	0.69654	0.54606	0.85483	3.51927	0.93915
	16H,AEL,SIG	0.68006	0.53386	0.78729	3.72621	0.93998
	16H,AEL,TANH	0.67258	0.52757	0.81443	3.71148	0.94022
	16H,SEL,SIG	0.71689	0.56306	0.84009	3.60085	0.93714
	16H,SEL,TANH	0.67619	0.53112	0.80164	3.56012	0.94064

Table III(a). Out-of-sample results for Japanese yen/US dollar conditional heteroscedastic models

Model	AAE	MAPE	MSE	Max AE	R-SQ
ARCH(1)	0.66056	0.51976	0.74205	3.78740	0.94344
GARCH(1,1)	0.66002	0.51933	0.74468	3.75438	0.94358
AGARCH(1,1)	0.66100	0.52009	0.74238	3.78579	0.94343
EGARCH(1,1)	0.66132	0.52034	0.74271	3.78216	0.94344
GARCH(1,1)-M	0.66018	0.51947	0.74178	3.78532	0.94343

在不同的基因工程神经网络中，使用稳健成本函数（绝对误差损失）的网络（使用AAE和MAPE）比使用常规平方误差损失函数的网络表现更好。从本次练习中得出的另一点是，在遗传前馈和遗传反馈网络之间没有太多区别。可能的原因是，在构建遗传前馈网络时，我们已经包括了足够的滞后和移动平均值作为输入变量，以填充初始种群（遗传搜索过程的起点）。

性能最好的遗传神经网络的性能相当令人鼓舞。对于德国马克/美元的案例研究，表现最佳的遗传神经网络的样本外平均绝对误差为6.06E-3阶，均方误差为7.49E-5阶，平均绝对百分比误差约为0.33%。对于日元/美元汇率，表现最好的遗传神经网络的平均绝对误差为0.63，平均平方误差为0.73，平均绝对百分比误差为0.49%。对于美元/英镑汇率，表现最佳的遗传神经网络的样本外平均绝对误差为5.1E-3阶，均方误差为4.8E-5阶，平均绝对百分比误差为0.31%。所有这些模型都记录了相当低的最大绝对误差和相当高的R平方值。

我们还观察到，条件异方差模型在大多数情况下比陷入局部极小的固定几何神经网络模型表现得更好。然而，在所考虑的所有情况下，表现最佳的遗传优化神经网络模型明显优于所有不同类型的条件异方差模型。

结论

在过去的几十年里，人们对外汇流动的建模和预测越来越感兴趣。由于汇率的变化具有非线性相关性，研究人员已经使用神经网络技术进行预测。研究表明，与传统的静态模型相比，人工神经网络模型具有更好的性能。传统人工神经网络方法的一个主要问题是，网络建设者必须主观地确定若干参数的值，如隐藏层的数目、每个隐藏层中的节点数目、节点数目等。因此，存在收敛到局部最小值而不是全局最小值的很大风险。

为了探索汇率预测模型的非线性，克服传统人工神经网络模型的不足，提出了一种利用人工神经网络和遗传算法优化技术建立汇率预测模型的方法。与传统的人工神经网络和统计时间序列建模方法相比，用该方法得到的样本外预测结果有显著的提高。将该方法与固定几何神经网络进行了详尽的比较，证明了该方法更适合于获得神经网络的最优拓扑。采用稳健代价函数的遗传神经网络，取得了最佳的实验结果。

作者传记:

Ashok K.Nag现任印度储备银行统计分析和计算机服务部主任。他获得了Calcutta印度统计研究所的学士、硕士和博士学位。他的研究兴趣包括将统计和人工智能技术应用于经济和金融数据、数据仓库和国民收入核算。Nag博士是印度储备银行公报的编辑委员会成员。他还是印度科学大会协会和印度国民收入和财富研究协会的成员。

Amit Mitra 分别在加尔各答大学University of Calcutta和坎普尔印度理工学院Indian Institute of Technology, Kanpur获得统计学理学学士和硕士学位，在这两所大学均获得第一名。他在坎普尔印度理工学院获得了统计信号处理领域的博士学位。他曾在瑞典乌普萨拉大学Uppsala University, Sweden,系统与控制系担任客座研究员一年。Mitra博士获得了印度统计研究所颁发的M.N.Murthy青年科学家奖，以表彰其在应用统计领域的最佳研究成果。目前，他在印度储备银行统计分析和计算机服务部担任助理顾问。Mitra 博士是统计和信号处理国际期刊上几篇文章的作者和合著者。他的研究兴趣包括统计信号处理、计算金融和神经网络。

